

PROYECTO FINAL • BIG DATA

Lumina Bank Sistema financiero unificado de DataLandia

Arquitectura de datos end-to-end sobre Google Cloud Platform, construida íntegramente bajo Infraestructura como Código.



ESCUELA DE POSGRADO •
2026

***HANDS
ON.***



MAESTRÍA EN
Ciencia de Datos e IA

Presentan hoy

- 01 Brajan Nieto Espinoza**
Contexto, objetivos y arquitectura
- 02 Sebastián López Medina**
Implementación detallada de la arquitectura
- 03 Mateo Tapia Chasquibol**
Valor, resultados, lecciones y roadmap

DOCENTE • ANITA QUEVEDO

20 minutos, seis tramos

- 01 Contexto y problemática del negocio
- 02 Objetivos del proyecto
- 03 Arquitectura end-to-end en GCP
- 04 Detalles de la implementación
- 05 KPIs, ROI y valor para el negocio
- 06 Desafíos, lecciones y roadmap futuro



Contexto y problemática del negocio

**HANDS
ON.**

DATALANDIA • 2026

Doce instituciones bancarias
independientes,
más de nueve millones de clientes,
una plataforma fragmentada.

El modelo fragmentado ya no es viable

01 Congestión de procesamiento

Alta latencia en quincena y fin de mes. Los sistemas legacy no escalan horizontalmente y los picos generan ventanas de indisponibilidad.

02 Fragmentación de entidades

Las doce instituciones no comparten información. No es posible detectar fraudes cruzados ni coordinar liquidez entre bancos.

03 Desajuste de infraestructura

Cajeros y sucursales subutilizados en zonas digitales y sobrecargados donde prima la atención humana. Sin analítica que alinee capacidad con demanda.

04 Ausencia de tiempo real

No hay procesamiento streaming. Se bloquea la oferta de micro-créditos bajo demanda y recomendaciones contextuales en el momento de la interacción.

LA ESCALA DEL DESAFÍO

Doce bancos. Nueve millones de clientes. Cero visibilidad compartida.

12

Instituciones bancarias

operando independientes en DataLandia

9 M+

Clientes atendidos

apps, cajeros, corresponsales y oficinas

0

Analítica en tiempo real

antes de Lumina Bank



OBJETIVO DEL PROYECTO

Una plataforma de datos unificada, que consolide las doce entidades en un sistema compartido, integrado y bajo demanda.

Habilitar decisiones en tiempo real sobre eventos transaccionales y una capa analítica consistente para los tres consumidores del sistema:

- 01 El regulador financiero
- 02 Las áreas de negocio de cada banco
- 03 El cliente final



Seis compromisos medibles

01

Consolidar el flujo transaccional

Pipeline único de ingesta con entrega at-least-once, retención de 31 días y captura automática de mensajes fallidos.

04

Pronósticos y métricas diarias

Liquidez por banco, utilización de la red física y scoring con 90 días de historia.

02

Evaluar el riesgo de fraude

Score en línea por cada transacción y decisión de aprobación o bloqueo devuelta al core bancario de origen.

05

Data Warehouse analítico

BigQuery particionado y clusterizado, conectado de forma nativa a Looker Studio y Power BI.

03

Distribuir con patrón fan-out

Transacciones aprobadas a cada banco respetando sus ritmos y sistemas internos.

06

Todo en Infraestructura como Código

Terraform para reproducibilidad, trazabilidad y facilidad de auditoría.



Cuatro fases sobre Google Cloud Platform

FASE · INGESTA → PROCESAMIENTO →
ALMACENAMIENTO → SERVICIO

01 · Ingesta	02 · Procesamiento	03 · Almacenamiento	04 · Servicio
12 bancos core bancario	Dataflow Streaming Apache Beam 2.56	Bigtable lookup caliente	Fan-out 12 suscripciones filtradas por bank_entity
Cloud Run API ingesta (escala 0→10)	Vertex AI Endpoint scoring fraude GBT	BigQuery DW analítico	BFF Cloud Run APIs para cada banco
Pub/Sub raw-ingest retención 31 días	Memorystore Redis reglas + features	Cloud Storage Data Lake bronze/silver/gold	Looker Studio · Power BI dashboards BigQuery
DLT mensajes fallidos	Dataproc Batch Spark MLlib diario	Redis cache sub-ms	Consola regulador reportes consolidados

Ingesta

Recibir transacciones de los 12 bancos, validarlas y publicarlas en un bus central con cero pérdida.



COMPONENTES PRINCIPALES

Cloud Run	API REST de ingesta, escala de 0 a 10 instancias por demanda.
Pub/Sub (raw-ingest)	Bus principal con 31 días de retención y entrega at-least-once.
Dead Letter Topic	Captura mensajes que fallan tras 5 intentos; auditables.
Schema Registry	Validación de contratos JSON por versión de banco.

Dato clave • Picos de quincena absorbidos sin intervención manual. Pub/Sub no tiene límite práctico de TPS.

Procesamiento

Enriquecer cada transacción con contexto, scorearla contra el modelo de fraude y decidir en menos de 200 ms.



COMPONENTES PRINCIPALES

Dataflow	Pipeline streaming en Apache Beam 2.56, autoescalado 5–20 workers.
Vertex AI	Endpoint del modelo GBT, 2–10 réplicas, scoring por transacción.
Memorystore Redis	Reglas anti-fraude y features calientes con latencia sub-milisegundo.
Dataproc	Clústers efímeros para jobs batch nocturnos (liquidez, cierres).

Dato clave • Fraude resuelto en menos de 200 ms con visibilidad interbancaria — imposible en el modelo fragmentado.

Almacenamiento polilítico

Cada tecnología opera dentro de su sweet spot de latencia y costo. Una sola base de datos no sirve para todo.



COMPONENTES PRINCIPALES

Redis	Cache sub-ms para decisiones en línea y estado de sesión.
Bigtable	Lookup caliente por transaction_id, ~10K ops/s por nodo.
BigQuery	Data warehouse con particionado por fecha y clustering por banco.
Cloud Storage	Data Lake en capas bronze, silver y gold con lifecycle a Nearline y Coldline.

Dato clave • Lifecycle automático: bronze a Nearline a los 30 días, Coldline al año. Ahorro 50–80% a largo plazo.

Servicio y consumo

Entregar los datos al banco correcto, al regulador y al cliente final — cada uno con su propia latencia y ritmo.

04 *HANDS ON.*

COMPONENTES PRINCIPALES

Fan-out Pub/Sub	12 suscripciones filtradas por bank_entity; cada banco consume a su ritmo.
BFF Cloud Run	APIs de consulta, score y pronóstico. Scale-to-zero fuera de horario pico.
Looker Studio	Dashboards analíticos nativos sobre BigQuery, sin ETL intermedio.
Consola regulador	Vistas consolidadas con linaje y acceso auditado.

Dato clave • Frescura típica en BigQuery de 2 a 5 segundos desde el evento; KPI exigía menos de 10 s.

CAPÍTULO II • PRESENTA SEBASTIÁN

Implementación detallada de la arquitectura

***HANDS
ON.***

STACK GCP • IAC • ML

Del diagrama a **terraform apply**.

Seis módulos Terraform reproducibles

Un despliegue completo corre en 12 a 15 minutos. Las aplicaciones incrementales, en menos de 5.

12-15 min

PRIMER DEPLOY

< 5 min

DEPLOY
INCREMENTAL

< 20 min

DESTROY & RECREATE

MÓDULO 01

network

VPC, subredes, VPC Connector, Private Service Access, Cloud NAT.

MÓDULO 02

ingesta

Pub/Sub raw-ingest, Cloud Run ingesta, DLT y suscripciones.

MÓDULO 03

streaming

Dataflow, Vertex AI Endpoint, Memorystore Redis, Bigtable.

MÓDULO 04

batch

Dataprocc efímero, jobs Spark MLlib, buckets temporales.

MÓDULO 05

serving

BFF Cloud Run, APIs de consulta, fan-out a 12 suscripciones.


MÓDULO 06

warehouse

BigQuery particionado, Cloud Storage bronze/silver/gold.



De la transacción a la decisión en < 200 ms



5K+ TPS

Throughput sostenido en quincena

exactly-once

Entrega garantizada por Dataflow

5-20

Workers autoescalados

31 días

Retención Pub/Sub



BATCH • DATAPROC EFÍMERO

Clústers que viven 45 minutos al día

Se crean bajo demanda para cada job, corren en paralelo y se destruyen al terminar. Ahorro superior al 95% frente a un clúster 24/7.

8 45 min 2 AM

nodos por job

duración media

corrida diaria

JOBS SPARK MLLIB

liquidity_forecast

Pronóstico diario de caja por bank_entity, horizonte 1–7 días.

network_utilization

Densidad de cajeros y sucursales vs demanda observada, por distrito.

fraud_training

Re-entrenamiento semanal del modelo GBT con 90 días de historia consolidada.

daily_closes

Cierres contables por banco, agregados y escritos a BigQuery bajo schema gold.



Gradient Boosted Trees sobre historia consolidada

El modelo GBT se entrena sobre el historial consolidado de los 12 bancos. Un cliente sospechoso en uno queda marcado automáticamente para todos.

ENTRENAMIENTO	Spark MLlib · Dataproc · semanal
SERVING	Vertex AI Endpoint · 2-10 réplicas
FEATURES	Memorystore Redis · reglas + agregados
SCORING	Dataflow invoca Vertex · < 200 ms p95

DETECCIÓN INTERBANCARIA


≥ 90%

de cobertura en la meta de fraude cruzado.
La arquitectura habilita la métrica y el
tuning del umbral fija el punto operativo.

**HANDS
ON.**



Fan-out filtrado para los 12 bancos



SEGURIDAD Y OBSERVABILIDAD

VPC Connector /28

Egreso controlado de Cloud Run a Redis y Bigtable.

Cloud NAT

Salida determinista a internet sin IPs públicas en workers.

Audit Logs + label pipeline

Trazabilidad de costos y acciones por subsistema.

Budgets 50/80/100%

Alertas por email y por pipeline (streaming, batch, serving).

CAPÍTULO III • PRESENTA MATEO

Valor, resultados y lecciones

***HANDS
ON.***

KPIS • ROI • ROADMAP

**Del diseño cumplido al
impacto en el negocio.**

Siete KPIs definidos, siete cumplidos

INDICADOR	META	COBERTURA DEL DISEÑO	STATUS
Throughput en picos	≥ 5.000 TPS	Cloud Run + Pub/Sub + Dataflow autoescalados; cuello real en Bigtable con holgura.	OK
Disponibilidad	≥ 99,95% mensual	Servicios multi-zona gestionados, cada uno con SLA ≥ 99,9%.	OK
Pérdida de mensajes	0	31 días de retención y DLT con 5 reintentos.	OK
Fraude cruzado	≥ 90%	GBT entrenado sobre historial consolidado de los 12 bancos.	OK
Frescura en BigQuery	< 10 s	Pub/Sub + Dataflow escriben con latencia típica 2–5 s.	OK
Pronóstico de liquidez	12 bancos · diario	Dataproc corre a las 2 AM y persiste en lumina_batch.liquidity_forecast.	OK
Despliegue end-to-end	≤ 15 min	terraform apply completo en 12–15 min; incrementales < 5 min.	OK

Tres capacidades que el modelo fragmentado no podía entregar

01

Fraude en tiempo real

Decisión en menos de 200 ms con visibilidad interbancaria. Un cliente marcado en un banco queda cubierto para los doce.

02

Liquidez accionable

Pronóstico diario por banco con horizonte 1-7 días. Las áreas de tesorería planifican caja con evidencia, no con intuición.

03

Productos de datos

Micro-créditos bajo demanda, scoring contextual y recomendaciones en el momento de la interacción con el cliente.

ESTIMACIÓN MENSUAL · US-EAST1

USD 4.160 – 7.630 al mes

Rango base con buffer para picos de quincena. Picos extremos hasta USD 12–15K. Rango manejable para una iniciativa que consolida 12 bancos y 9 M de clientes.

Dataflow (streaming)	5–20 workers autoescalados	\$ 1.800 – 3.500
Vertex AI Endpoint	2–10 réplicas autoescaladas	\$ 400 – 900
Cloud Bigtable	1 nodo, volumen medio	\$ 650 – 700
BigQuery on-demand	~5 TB escaneados/mes	\$ 200 – 600
Dataproc (batch diario)	8 nodos × 45 min/día	\$ 350 – 500
Pub/Sub	~500 TPS, 43 GB/día	\$ 300 – 500
Cloud Run (ingesta + BFF)	Min 2, picos 30 instancias	\$ 150 – 300
Cloud Storage (Data Lake)	5 TB con lifecycle	\$ 100 – 200
Redis, NAT, Logging, CI/CD	Stack de soporte	\$ 210 – 430

PALANCAS APLICADAS

Dataproc efímero

> 95% de ahorro vs clúster 24/7

GCS lifecycle

50–80% menos a largo plazo

Cloud Run scale-to-zero

SaaS-like sin GKE permanente

Particionado BigQuery

Hasta 90% menos TB escaneados

HANDS
ON.



Seis fricciones reales y su resolución

01

Cuotas GCP en modo trial

CPUs Dataflow, IPs, slots BigQuery. Solicitar aumentos antes del primer apply y serializar con depends_on.

02

Permisos IAM por defecto

Cloud Functions v2 y Cloud Run usan la SA default de Compute. Asignar Cloud Build, Logging, Storage y Artifact Registry explícitamente.

03

VPC Connector y CIDRs

Documentar un plan de rangos desde el día uno. El /28 del conector es obligatorio para Cloud Run.

04

Mismatch SDK en Dataflow

Imagen Docker basada en apache/beam_python3.12_sdk:2.56.0 para alinear worker y launcher.

05

APIs habilitadas asíncronas

time_sleep de 60 s tras activar APIs elimina fallos esporádicos en el primer terraform apply.

06

Bucket temporal Dataproc

spark-bigquery requiere temporaryGcsBucket dedicado con lifecycle agresivo de 7 días.

Transversal • priorizar servicios gestionados, escribir desde el inicio en IaC, documentar IAM dentro de cada módulo, y monitorear consumo con budgets desde el día uno.



Tres extensiones naturales

HORIZONTE · H1

Feature Store en Vertex AI

Versionar las features que alimentan el modelo de fraude y evitar drift entre entrenamiento e inferencia.

HORIZONTE · H2

BigQuery ML + Gemini Pro

Migrar scoring a queries SQL + LLM.
Habilita un agente que responda al regulador directamente contra el warehouse.

HORIZONTE · H3

Dataplex como capa de gobierno

Linaje automático y políticas de clasificación de PII sobre el data lake y BigQuery, unificando el catálogo.

Cada fase agrega capacidades sin invalidar las anteriores. Apache Beam, Spark, Redis, Parquet y Docker protegen la inversión frente a cualquier cambio futuro de proveedor.



CONCLUSIONES

Lumina Bank no es solo una plataforma técnica

Es la fundación sobre la cual DataLandia puede construir su sistema financiero de próxima generación.

Exactly-once sin Kafka

Pub/Sub + Dataflow absorben picos sin intervención manual.

Fan-out elegante

12 suscripciones filtradas resuelven la fragmentación sin acoplamientos.

Polilítico intencional

Cada base en su sweet spot de latencia y costo — no dogmatismo.

laC reproducible

Destruir y recrear toda la infra en menos de 20 minutos.




POSGRADO UTEC · LUMINA BANK

Gracias.

Preguntas del comité.



BRAJAN NIETO · SEBASTIÁN LÓPEZ · MATEO TAPIA



***HANDS
ON.***